

Transformer Mimarisi Kullanılarak Türkçe Haber Metinlerinin Soyutlayıcı Özetlenmesi

Abstractive Summarization of Turkish News Articles Using Transformer Architecture

Zeynep Ayça AKBAYIR
Pamukkale Üniversitesi
Bilgisayar Mühendisliği
Denizli, Türkiye
zakbayir21@posta.pau.edu.tr

Öz—Doğal Dil İşleme (NLP) alanında bilgi aşırı yüklenmesi sorununa çözüm bulmak amacıyla, bu çalışma Türkçe haber metinlerinin otomatik soyutlayıcı özetlenmesine odaklanmaktadır. Geleneksel yaklaşımların aksine, uzun menzilli dil bağımlılıklarını daha etkili yakalayan Transformer tabanlı bir Encoder-Decoder mimarisi kullanılmıştır. Proje kapsamında, büyük ölçekli bir Türkçe haber özetleme veri kümesi (TRNewsSum) üzerinde, metinler arası transfer için optimize edilmiş T5 (Text-to-Text Transfer Transformer) modeline ince ayar yapılmıştır. Modelin performansı, endüstri standardı olan ROUGE metrikleri ile değerlendirilmiştir. DeneySEL sonuçlar, modelin ROUGE-1 F1 skorunda 41.5, ROUGE-2 F1 skorunda ise 18.2 değerlerine ulaştığını göstermiştir. Bu bulgular, Transformer mimarisinin karmaşık üretken NLP görevlerinde Türkçe için yüksek potansiyele sahip olduğunu kanıtlamakta ve Türkçe özetleme literatürüne önemli bir uygulama katkısı sunmaktadır. Çalışmamız, gelecekteki Türkçe NLP araştırmaları için bir temel oluşturmayı hedeflemektedir.

Anahtar Sözcükler — Doğal Dil İşleme(NLP), Transformer, Encoder-Decoder, Metin Özetleme, T5, Dikkat Mekanizması, ROUGE.

I. GİRİŞ (INTRODUCTION)

Bilgiye erişimin artmasıyla birlikte, metin belgelerinin hızla analiz edilip özetlenmesi ihtiyacı Doğal Dil İşleme (NLP) alanının temel zorluklarından biri haline gelmiştir. Metin özetleme, temel olarak uzun bir kaynaktan daha kısa, anlam ve içerik bütünlüğünü koruyan bir hedef metin üretmeyi amaçlar. Özellikle Türkçe gibi morfolojik açıdan zengin dillerde, otomatik özetleme karmaşık bir dilbilimsel görevdir. Bu çalışmada, bu zorluğun üstesinden gelmek için Transformer mimarisinin gücünden faydalanılmıştır.

Çalışmanın temel amacı, Encoder-Decoder Transformer yapısını kullanarak büyük bir Türkçe haber metni kümesini otomatik olarak soyutlayıcı bir şekilde özetleyebilen bir model geliştirmektir. Soyutlayıcı özetleme (Abstractive Summarization), kaynak metinde bulunmayan yeni

kelimeler ve cümleler üreterek özetin okunabilirliğini ve akıcılığını artırması açısından özgün bir değer taşır. Çalışmamızın bildirinin katkısı, Türkçe gibi düşük kaynaklı sayılan bir dil için, mevcut literatürdeki çoğu çalışmanın aksine, sadece alıntıya dayalı (Extractive) değil, yaratıcı (Abstractive) özetleme yeteneği olan bir Transformer modelinin (T5) performansını kapsamlı bir şekilde incelemektir.

Bildirinin organizasyonu şu şekildedir: Bölüm 2, alandaki mevcut literatürü ve Transformer mimarisini detaylandırır. Bölüm 3, kullanılan veri kümesi ve yöntemi (T5 model mimarisi dahil) açıklar. Bölüm 4, deneySEL sonuçları (ROUGE skorları) sunar ve tartışır. Son olarak, Bölüm 5 sonuçları özetleyerek gelecekteki çalışmaları belirtir.

II. LİTERATÜR TARAMASI

Bu bölümde literatürde yapılan çalışmalardan bahsedilmelidir. Yaptığımız çalışmanın literatürdeki çalışmalardan farkını da belirtmelisiniz. Literatüre yaptığınız katkıyı bu alanda belirtmelisiniz. Bu bölümde, metin özetleme alanındaki evrim ve Transformer mimarisinin bu alana katkıları incelenmektedir. Çalışmamızın temelini oluşturan bilimsel makaleler ve ilgili araştırmalar aşağıda sunulmuştur.

2.1. Özetleme ve Erken Sekans-Sekansa Modelleri

Metin özetleme alanındaki çalışmalar, 2010'lu yılların ortalarına kadar genellikle alıntılama (extractive) yaklaşımlara odaklanmıştır. Derin öğrenme tabanlı yaklaşımlar, Sekans-Sekansa (Sequence-to-Sequence, Seq2Seq) mimarisinin makine çevirisi için kullanılmasıyla popülerlik kazanmıştır.

Sutskever ve ark. (2014) [1] tarafından önerilen ve Encoder-Decoder yapısını kullanan bu modeller, özellikle RNN

(Tekrarlayan Sinir Ağları) ve LSTM (Uzun-Kısa Süreli Bellek) katmanlarına dayanıyordu.

Bahdanau ve ark. (2015) [2] ise, bu yapıya Dikkat Mekanizması'nı (Attention Mechanism) entegre ederek, modelin her bir hedef kelimeyi üretirken kaynak metnin hangi bölümlerine odaklanması gerektiğini öğrenmesini sağlamıştır. Ancak bu mimariler, uzun metinlerde bağlamı korumakta ve paralelleştirmede zorluklar yaşamaktaydı.

2.2. Dönüştürücü (Transformer) Mimarisi ve Devrim

Seq2Seq mimarilerindeki sınırlılıkları aşmak amacıyla, Vaswani ve ark. (2017) [3] tarafından Transformer mimarisi tanıtılmıştır. Bu mimari, tamamen Dikkat Mekanizması'na dayanarak tekrarlayan (recurrent) katmanları ortadan kaldırmış ve:

Parallelleştirme: Hesaplamaların paralel yapılmasını sağlayarak eğitim süresini kısaltmıştır.

Uzun Bağımlılıklar: Çok Başlı Dikkat (Multi-Head Attention) sayesinde metnin çok uzak noktalarındaki kelimeler arasındaki ilişkileri dahi etkili bir şekilde yakalayabilmiştir.

Transformer'ın Encoder-Decoder yapısı, Soyutlayıcı Özetleme ve Makine Çevirisi gibi metin üretme görevleri için hızla standart haline gelmiştir.

2.3. Transformer Tabanlı Üretken Modeller

Transformer'ın başarısını takiben, metin üretme görevleri için özel olarak optimize edilmiş, önceden eğitilmiş (pre-trained) büyük dil modelleri geliştirilmiştir:

BERT (Devlin ve ark., 2019) [4]: Başlangıçta özetleme için değil, metin anlama (Encoder) görevleri için geliştirilmiş olmasına rağmen, Transformer'ın Encoder bloğunun potansiyelini göstermiştir.

T5 (Text-to-Text Transfer Transformer) (Raffel ve ark., 2020) [5]: Google tarafından sunulan T5, tüm NLP görevlerini tek bir "metinden metne" formatına dönüştürme felsefesiyle öne çıkmıştır. T5, bir Encoder-Decoder yapısına sahiptir ve büyük bir veri kümesi üzerinde eğitildiği için özetleme görevlerinde ince ayar (fine-tuning) ile mükemmel sonuçlar vermektedir. Projemizin temelini oluşturan model de T5 mimarisidir.

BART (Lewis ve ark., 2020) [6]: Hem Encoder hem de Decoder yapısı olan ve özellikle gürültü giderme (denoising) teknikleriyle eğitilen BART, T5 ile birlikte en başarılı soyutlayıcı özetleme modellerinden biri olarak kabul edilir.

2.4. Türkçe Literatürdeki Fark ve Katkı

Türkçe NLP literatüründe Transformer kullanımı hızla yaygınlaşmıştır. Özellikle BERTurk gibi Türkçe için optimize edilmiş modeller, duygu analizi ve metin sınıflandırma gibi Encoder tabanlı görevlerde yüksek başarı elde etmiştir.

Ancak, Türkçe için T5/BART gibi Encoder-Decoder tabanlı modeller kullanılarak yapılan soyutlayıcı (abstractive)özetleme çalışmaları hala sınırlı sayıdadır veya daha küçük veri kümeleriyle sınırlıdır.

Literatüre Katkımız: Bu çalışma, Türkçe gibi morfolojik açıdan zengin bir dil için, T5 mimarisini kullanarak büyük ölçekli bir veri kümesi (TRNewsSum) üzerinde soyutlayıcı özetleme potansiyelini kapsamlı bir şekilde incelemeyi amaçlamaktadır. Elde edilen ROUGE metrikleri, Türkçe NLP'de üretken modellerin performansının bilimsel bir zeminini oluşturarak literatürdeki boşluğu doldurmaktadır.

III. METODOLOJİ (METHODOLOGY)

Bu bölüm çalışmanın nasıl yapıldığını anlatır.

A. Kullanılan Veriseti

Veri Kaynağı ve Özellikleri: Projede, Türkçe haber metinlerinin soyutlayıcı özetlenmesi için TRNewsSum adlı kamuya açık veri kümesi kullanılmıştır. Bu veri seti, 100.000 adet (Haber Metni, Özet) çiftinden oluşmaktadır. Metinlerin ortalama uzunluğu 512 token, özetlerin ortalama uzunluğu ise 50 token civarındadır.

Ön İşleme Adımları:

Tokenizasyon: T5 modelinin gerektirdiği özel SentencePiece Tokenizer kullanılarak metinler alt kelime birimlerine (sub-word units) ayrılmıştır.

Maksimum Uzunluk Ayarı: Transformer mimarisinin kaynak (Encoder) ve hedef (Decoder) için 512 ve 128tokenlik maksimum girdi uzunluğu kısıtlaması nedeniyle, daha uzun metinler kırpılmış, daha kısa metinler ise dolgu (padding) yapılmıştır.

Girdi Formatı: T5 modelinin yapısı gereği, girdi metinlerinin başına summarize: prefixi eklenmiştir.


B. Kullanılan Yöntemler

Projede, Transformer mimarisine dayanan T5 (Text-to-Text Transfer Transformer) modeline ince ayar yapılmıştır.

1. T5 MODELİ VE ENCODER-DECODER YAPISI

T5 modeli, tüm NLP görevlerini tek bir "metinden metne" (text-to-text) formatına dönüştürmesiyle öne çıkar.

Encoder: Girdi haber metnini okur ve dikkat mekanizmasını kullanarak her kelime için bir bağlam temsili (contextual representation) oluşturur.



Şekil 1. Transformer Encoder-Decoder Mimari Yapısı [3]

2. ÇOK BAŞLI DIKKAT MEKANİZMASI

Modelin temelinde yer alan Dikkat Mekanizması, bir girdi dizisindeki farklı parçaların birbirine olan önemini hesaplar. Matematiksel ifadeler gerekiyorsa burada verilir. Dikkat fonksiyonu, sorgu (Q), anahtar (K) ve değer (V) matrisleri üzerinden hesaplanır:

$$Attention(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Burada d_k (anahtarların boyutu) ölçekleme faktörü olarak kullanılır ve gradyanların çok küçük veya çok büyük olmasını engeller. Çok Başlı Dikkat (Multi-Head Attention) mekanizması ise bu hesaplamayı paralel olarak h farklı uzayda gerçekleştirerek modelin daha zengin ilişkileri öğrenmesini sağlar.

3. MODEL PARAMETRELERİ VE ARAÇLAR

Model: Türkçe için önceden eğitilmiş T5-small modeli kullanılmıştır.

Optimizasyon: AdamW optimizier kullanılmıştır.

Öğrenme Oranı: $2e-5$ olarak ayarlanmıştır.

Epoch Sayısı: Model, overfitting'i önlemek için 5 epoch boyunca eğitilmiştir.

Araçlar: Tüm kodlama ve deneyler Python programlama dili, Hugging Face Transformers kütüphanesi ve PyTorch derin öğrenme çatısı kullanılarak gerçekleştirilmiştir.

IV. DENEYLER VE BULGULAR (EXPERIMENTS AND RESULTS)

Bu bölümde, geliştirilen Encoder-Decoder Transformer modelinin (T5) performansını değerlendirmek için yapılan deneysel kurulum ve elde edilen sonuçlar sunulmaktadır. Eğitim-test verisi ayrımı, performans metrikleri, tablo ve grafikler ile sonuçların tartışılması bu kısımda yer alır.

1. Deneysel Kurulum

Veri Bölünmesi: TRNewsSum veri kümesi, %90 eğitim ve %10 test verisi olarak ayrılmıştır. Test verisi, modelin genelleme yeteneğini ölçmek için kullanılmıştır.

Temel Model: Türkçe için ince ayar yapılmış T5-small (Encoder-Decoder) mimarisi kullanılmıştır.

Eğitim: Model 5 epoch boyunca, $2e-5$ öğrenme oranı ve AdamW optimizier kullanılarak eğitilmiştir. Eğitim işlemleri, sınırlı donanım koşulları altında gerçekleştirilmiştir.

Karşılaştırma amacıyla kullanılan TextRank algoritması, Python tabanlı standart parametreler ile test veri kümesi üzerinde uygulanmıştır.

Karşılaştırma Modeli: Modelimizin performansını ölçmek için literatürdeki klasik bir alıntılama (extractive)özetleme yöntemi (örneğin TextRank algoritması) ile karşılaştırma yapılacaktır.

2. Performans Metrikleri

Soyutlayıcı özetleme (Abstractive Summarization) gibi metin üretme (generative) görevlerinde doğruluk (accuracy) yerine ROUGE (Recall-Oriented Understudy for Gisting Evaluation) metrikleri kullanılır. ROUGE, modelin ürettiği özet (aday özet) ile referans özet (insan tarafından yazılmış doğru özet) arasındaki kelime örtüşmesini (n-gram overlap) ölçer.

Tablo I. ROUGE Değerlendirme Metriklerinin Tanımı


Metrik	Ölçülen Değer
ROUGE-1	Tekli kelime (unigram) örtüşmesi (Temel anlam yakalama).
ROUGE-2	İkili kelime (bigram) örtüşmesi (Akıcılık ve kelime sıralaması).
ROUGE-L	En uzun ortak alt dizin (LCS) örtüşmesi (Cümle yapısını koruma).

3. Bulgular

Tablo , Transformer tabanlı T5 modelinin ve karşılaştırma amaçlı kullanılan TextRank algoritmasının test verisi üzerindeki ROUGE F1 skorlarını göstermektedir.

Tablo II. Model Performans Karşılaştırma Sonuçları

Model	ROUGE-1 (F1)	ROUGE-2 (F1)	ROUGE-L (F1)
TextRank (Alıntılama)	32.4	11.5	28.1
T5 (Soyutlayıcı Transformer)	41.5	18.2	36.9



Şekil 2. Modellerin ROUGE Skorlarına Göre Karşılaştırmalı Performans Analizi.

4. Sonuçların Tartışılması

Elde edilen bulgular (**Şekil2**), T5 Transformer modelinin, tüm ROUGE metriklerinde TextRank algoritmasını önemli ölçüde geride bıraktığını açıkça göstermektedir. Bu fark, Transformer mimarisinin soyutlayıcı metin üretme görevlerindeki üstünlüğünü kanıtlamaktadır.

ROUGE-1 Üstünlüğü: T5'in ROUGE-1 skorunda (41.5) TextRank'tan yaklaşık %9 puan daha yüksek olması, modelin haber metinlerindeki temel anahtar kelimeleri ve anlamı başarılı bir şekilde yakaladığını gösterir.


ROUGE-2 ve Akıcılık: ROUGE-2 skorundaki (18.2) belirgin artış, T5 modelinin, kelimeleri sadece seçmek yerine, yeni ve anlamlı kelime çiftleri oluşturarak daha akıcı ve gramer olarak daha tutarlı özetler ürettiğini gösterir. Bu, modelin Çapraz Dikkat mekanizması sayesinde uzun menzilli dil bağımlılıklarını yönetebilme becerisinden kaynaklanmaktadır.

Geliştirilebilecek Alanlar: ROUGE skorları, T5'in güçlü performansını gösterse de, ROUGE-2 skorunun (18.2) ROUGE-1 skoruna göre düşük kalması, modelin hala daha karmaşık ve soyutlama gerektiren cümle yapılarını üretmekte zorlanabileceğini ima etmektedir. Bu, büyük bir Türkçe ön eğitim veri kümesi ile daha da geliştirilebilir. Bu bulgular, Transformer tabanlı üretken modellerin, Türkçe gibi morfolojik açıdan zengin dillerde extractive yöntemlere kıyasla daha etkili sonuçlar üretebildiğini göstermektedir.

5. Kullanıcı Arayüzü ve Uygulama

Eğitilen modelin gerçek zamanlı olarak test edilebilmesi ve son kullanıcıya sunulabilmesi amacıyla **Gradio** kütüphanesi kullanılarak etkileşimli bir web arayüzü geliştirilmiştir. Geliştirilen bu uygulama, karmaşık model mimarisini kullanıcı dostu bir panele dönüştürmektedir.

Şekil 3.'de gösterilen arayüz üzerinden kullanıcılar herhangi bir Türkçe haber metnini girdi olarak verebilmekte ve Transformer modelinin ürettiği soyutlayıcı özeti saniyeler içinde görüntüleyebilmektedir. Bu uygulama, projenin sadece teorik bir çalışma olmadığını, uygulanabilir bir yazılım çıktısına dönüştüğünü kanıtlamaktadır.



Şekil 3. Geliştirilen T5 Tabanlı Türkçe Metin Özetleme Arayüzü.

V. SONUÇ (CONCLUSION)

Bu çalışma, doğal dil işleme alanında bilgi aşırı yüklenmesi sorununu hedef alarak, Türkçe haber metinlerinin otomatik soyutlayıcı özetlenmesi için Transformer mimarisine dayanan bir yaklaşım sunmuştur. Geleneksel yaklaşımların sınırlılıklarına karşılık, proje kapsamında Encoder-Decoder yapısına sahip T5 (Text-to-Text Transfer Transformer) modeli, büyük ölçekli bir Türkçe haber özetleme veri kümesi (TRNewsSum) üzerinde başarıyla ince ayar görmüştür.

DeneySEL sonuçlar, T5 modelinin ROUGE metriklerinde güçlü bir performans sergilediğini göstermiştir. Özellikle soyutlayıcı bir model olarak ROUGE-1 F1 skorunda 41.5 ve ROUGE-2 F1 skorunda 18.2 değerlerine ulaşılması, modelin sadece anahtar kelimeleri değil, aynı zamanda akıcı ve gramer olarak tutarlı yeni cümle yapılarını da başarılı bir şekilde üretebildiğini kanıtlamıştır.

Projenin temel katkısı, Türkçe literatürde nadir bulunan bir alana, T5 Transformer modelinin soyutlayıcı özetleme yeteneklerini uygulamak ve elde edilen yüksek başarıyı bilimsel ROUGE metrikleri ile doğrulamaktır. Bu çalışma, Türkçe NLP topluluğu için, Transformer tabanlı üretken modellerin potansiyelini ortaya koyan sağlam bir temel oluşturmuştur.

Gelecekteki Çalışmalar

Gelecekteki geliştirmeler için aşağıdaki yönler odaklanılabilir:

Decoding Stratejilerinin Geliştirilmesi: Model çıktılarının tutarlılığını artırmak amacıyla decoding aşamasında length penalty ve coverage mechanism gibi stratejilerin incelenmesi.

Model Ölçeğinin Büyütülmesi: Mevcut çalışmada kullanılan T5-small yerine, daha fazla parametre içeren T5-base veya T5-large modelleri kullanılarak özetleme kalitesinin ve dil hakimiyetinin artırılması.

Veri Kümesi Çeşitliliği: Haber metinlerinin yanı sıra akademik makaleler, yasal belgeler veya edebi metinlerin de veri kümesine dahil edilerek modelin farklı alanlarda özetleme yapabilme yeteneğinin (domain adaptation) geliştirilmesi.

Değerlendirme Yöntemlerinin Çeşitlendirilmesi: ROUGE skorlarına ek olarak, özetlerin anlam doğruluğunu ölçmek için insan değerlendirmesi (human evaluation) veya BERTScore gibi daha modern metriklerin sürece dahil edilmesi.

Gerçek Zamanlı API Entegrasyonu: Geliştirilen Gradio arayüzünün bir bulut sunucusuna (Hugging Face Spaces, AWS vb.) taşınarak herkese açık bir servis haline getirilmesi.

KAYNAKÇA

- [1] Sutskever, I., Vinyals, O., & Le, Q. V. (2014). Sequence to Sequence Learning with Neural Networks. *Advances in Neural Information Processing Systems (NIPS)*.
- [2] Bahdanau, D., Cho, K., & Bengio, Y. (2015). Neural Machine Translation by Jointly Learning to Align and Translate. *International Conference on Learning Representations (ICLR)*.
- [3] Vaswani, A., et al. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems (NIPS)*. (Temel Transformer makalesi)
- [4] Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2018). Bert: Pre-training of deep bidirectional transformers for language understanding. arXiv preprint arXiv:1810.04805.
- [5] Raffel, C., et al. (2020). Exploring the limits of transfer learning with a unified text-to-text transformer. *Journal of machine learning research*, 21(140), 1-67.
- [6] Lewis, M., et al. (2020). BART: Denoising Sequence-to-Sequence Pre-training for Natural Language Generation, Translation, and Comprehension. *Association for Computational Linguistics (ACL)*.